Practica 5. Optimización por Colonia de Hormigas

Algoritmos Bioinspirados

Diego Castillo Reyes Marthon Leobardo Yañez Martinez Aldo Escamilla Resendiz

6 de junio de 2024

Índice general

1. Introducción

El Algoritmo de Optimización por Colonia de Hormigas (ACO, por sus siglas en inglés) es una técnica metaheurística inspirada en el comportamiento de las hormigas en la naturaleza. Este algoritmo, propuesto inicialmente por Marco Dorigo en la década de 1990, simula la forma en que las hormigas encuentran caminos óptimos entre su colonia y una fuente de alimento.

En la naturaleza, las hormigas depositan feromonas en su camino al buscar comida, creando un rastro químico que guía a otras hormigas. Con el tiempo, los caminos con más feromonas se vuelven más atractivos, y las hormigas tienden a seguir estos senderos más prometedores, lo que eventualmente conduce a la convergencia en el camino más corto.

El ACO utiliza este principio para resolver problemas de optimización combinatoria. En este algoritmo, una colonia de hormigas artificiales construye soluciones al problema, y durante este proceso, cada hormiga deposita feromonas en el entorno, influyendo en las decisiones de las hormigas subsiguientes. Los caminos que resultan en mejores soluciones reciben más feromonas, aumentando la probabilidad de ser seleccionados en iteraciones futuras.

2. Problema de Asignación Cuadrática

```
Resolver el problema de asignacion
   cuadratica usando ACO.
4
   import numpy as np
   import itertools
   def selecciona_siguiente_ciudad(actual, no_visitadas, feromona, distancia, alpha, beta, epsilon=1e
       feromona_actual = feromona[actual][no_visitadas] ** alpha
9
       visibilidad = (1.0 / (distancia[actual][no_visitadas] + epsilon)) ** beta
       probabilidades = feromona_actual * visibilidad
11
12
       # Chequear y manejar valores infinitos o NaN en probabilidades
13
14
       if np.any(np.isinf(probabilidades)) or np.any(np.isnan(probabilidades)):
           probabilidades = np.nan_to_num(probabilidades, nan=epsilon, posinf=epsilon, neginf=epsilon
15
16
       suma_probabilidades = sum(probabilidades)
17
18
       # Chequear si la suma de probabilidades es cero o infinito para evitar NaNs
       if suma_probabilidades == 0 or np.isinf(suma_probabilidades) or np.isnan(suma_probabilidades):
           probabilidades = np.ones_like(probabilidades) / len(probabilidades)
21
22
           probabilidades /= suma_probabilidades
23
24
       return np.random.choice(no_visitadas, 1, p=probabilidades)[0]
25
26
27
   def construye_camino(inicio, n_ciudades, feromona, distancia, alpha, beta):
       camino = [inicio]
28
       no_visitadas = list(range(n_ciudades))
29
       no_visitadas.remove(inicio)
```

```
31
32
        actual = inicio
       while no_visitadas:
33
           siguiente = selecciona_siguiente_ciudad(actual, no_visitadas, feromona, distancia, alpha,
34
        beta)
            camino.append(siguiente)
35
            no_visitadas.remove(siguiente)
36
            actual = siguiente
37
38
        return camino
39
40
41
   def computa_costo(camino, distancia, flujo):
42
        costo = 0
        for i in range(len(camino)):
43
44
            for j in range(len(camino)):
                costo += flujo[i][j] * distancia[camino[i]][camino[j]]
45
46
        return costo
47
48
   def actualiza_feromona(feromona, caminos, costos, evaporacion, q):
49
        feromona *= (1.0 - evaporacion)
        for camino, costo in zip(caminos, costos):
50
            for i in range(len(camino) - 1):
51
                feromona[camino[i]][camino[i+1]] += q / costo
52
            feromona[camino[-1]][camino[0]] += q / costo
53
54
   def aco(distancia, flujo, n_hormigas, n_iteraciones, evaporacion, alpha=1, beta=5, q=1):
55
       n_ciudades = distancia.shape[0]
56
        feromona = np.ones(distancia.shape) / n_ciudades
57
58
        mejor_camino = None
59
60
        mejor_costo = float('inf')
61
        for _ in range(n_iteraciones):
62
63
            caminos = [construye_camino(np.random.choice(n_ciudades), n_ciudades, feromona, distancia,
        alpha, beta) for _ in range(n_hormigas)]
            costos = [computa_costo(camino, distancia, flujo) for camino in caminos]
64
            actualiza_feromona(feromona, caminos, costos, evaporacion, q)
65
           min_costo = min(costos)
66
            if min_costo < mejor_costo:</pre>
67
                mejor_costo = min_costo
68
69
                mejor_camino = caminos[costos.index(min_costo)]
70
71
        return mejor_camino, mejor_costo
72
   def leer_matrices(file_path):
73
74
        with open(file_path, 'r') as file:
           lines = file.readlines()
75
76
        matrices = []
77
78
        current_matrix = []
79
        for line in lines:
            stripped_line = line.strip()
80
            if stripped_line:
81
                current_matrix.append(list(map(int, stripped_line.split())))
82
            else:
83
84
                if current_matrix:
                    matrices.append(np.array(current_matrix))
85
                    current_matrix = []
86
87
        if current matrix:
           matrices.append(np.array(current_matrix))
88
89
        return matrices
90
91
   def ANOVA(distancia, flujo, n_iteraciones, evaporacion, alphas, betas, n_hormigas):
92
93
        resultados = []
        combinaciones = list(itertools.product(n_hormigas, alphas, betas))
94
95
        for n_h, alpha, beta in combinaciones:
96
           mejor_camino, mejor_costo = aco(distancia, flujo, n_h, n_iteraciones, evaporacion, alpha,
97
        beta)
           resultados.append((n_h, alpha, beta, mejor_camino, mejor_costo))
```

```
99
       return resultados
100
   # Usar las matrices leídas
   # ! Cambiar el path al archivo
   # file_path = 'Algoritmos Bioinspirados/Practica 5/matricesProblemaQAP/matricesProblemaQAP/tai15.
104
   file_path = 'matricesProblemaQAP/matricesProblemaQAP/tai30.dat'
   matrices = leer_matrices(file_path)
106
   distancia = matrices[1]
107
   flujo = matrices[2]
108
   # Definir los parámetros
110
   n_{\text{hormigas}} = [10, 25, 50, 100]
   alphas = [50, 100, 200]
112
   betas = [2, 10]
113
114
   n_{iteraciones} = 100
    evaporacion = 0.5
115
116
117
   # Ejecutar experimentos
   resultados = ANOVA(distancia, flujo, n_iteraciones, evaporacion, alphas, betas, n_hormigas)
118
119
   # Imprimir resultados
120
   for i, (n_h, alpha, beta, mejor_camino, costo) in enumerate(resultados):
121
       mejor_camino}, Costo: {costo}")
```

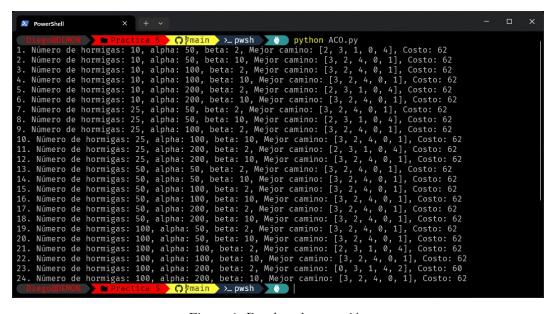


Figura 1: Pruebas de regresión

```
1. Número de hormigas: 10, alpha: 50, beta: 2, Mejor camino: [3, 1, 6, 8, 11, 9, 0, 4, 2, 5, 7, 10], Costo: 276220
2. Número de hormigas: 10, alpha: 50, beta: 10, Mejor camino: [4, 6, 1, 10, 11, 8, 0, 9, 3, 7, 5, 2], Costo: 285030
3. Número de hormigas: 10, alpha: 100, beta: 10, Mejor camino: [3, 4, 5, 1, 6, 0, 8, 10, 2, 9, 11, 7], Costo: 261538
4. Número de hormigas: 10, alpha: 100, beta: 10, Mejor camino: [1, 2, 6, 3, 7, 5, 11, 0, 4, 9, 8, 10], Costo: 257430
5. Número de hormigas: 10, alpha: 200, beta: 10, Mejor camino: [1, 2, 6, 3, 7, 5, 11, 0, 4, 9, 8, 10], Costo: 257430
6. Número de hormigas: 25, alpha: 50, beta: 2, Mejor camino: [3, 4, 9, 5, 2, 6, 0, 10, 7, 11, 8, 1], Costo: 262076
7. Número de hormigas: 25, alpha: 50, beta: 10, Mejor camino: [1, 6, 0, 11, 8, 2, 5, 7, 3, 10, 4, 9], Costo: 276834
8. Número de hormigas: 25, alpha: 100, beta: 2, Mejor camino: [1, 6, 0, 11, 8, 2, 5, 7, 3, 10, 4, 9], Costo: 2576334
8. Número de hormigas: 25, alpha: 100, beta: 2, Mejor camino: [1, 6, 0, 11, 8, 2, 5, 7, 3, 10, 4, 9], Costo: 258888
10. Número de hormigas: 25, alpha: 100, beta: 2, Mejor camino: [1, 6, 0, 11, 8, 2, 5, 7, 3, 10, 4, 9], Costo: 258888
11. Número de hormigas: 25, alpha: 200, beta: 10, Mejor camino: [7, 8, 0, 10, 1, 6, 4, 9, 5, 11, 2, 3], Costo: 254928
12. Número de hormigas: 25, alpha: 200, beta: 10, Mejor camino: [9, 5, 11, 1, 6, 7, 0, 4, 3, 10, 8, 2], Costo: 258672
13. Número de hormigas: 50, alpha: 50, beta: 10, Mejor camino: [9, 5, 11, 1, 6, 7, 0, 4, 3, 10, 8, 2], Costo: 258672
14. Número de hormigas: 50, alpha: 50, beta: 2, Mejor camino: [7, 2, 5, 11, 8, 6, 1, 10, 3, 9, 0, 1], Costo: 272696
15. Número de hormigas: 50, alpha: 50, beta: 10, Mejor camino: [7, 2, 5, 11, 8, 6, 1, 10, 3, 9, 0, 1], Costo: 272696
16. Número de hormigas: 50, alpha: 50, beta: 10, Mejor camino: [7, 0, 8, 1, 3, 9, 2, 5, 6, 4, 11, 10], Costo: 258872
18. Número de hormigas: 50, alpha: 200, beta: 2, Mejor camino: [7, 0, 8, 1, 3, 9, 2, 5, 6, 4, 11, 10], Costo: 258896
19. Número de hormigas: 50, alpha: 200, beta: 2, Mejor camino:
```

Figura 2: Pruebas de regresión

```
Número de hormigas: 10, alpha: 50, beta: 2, Mejor camino: [1, 11, 3, 2, 13, 12, 6, 7, 4, 5, 8, 0, 9, 10, 14], Costo: 444856
Número de hormigas: 10, alpha: 50, beta: 10, Mejor camino: [13, 12, 8, 5, 14, 1, 3, 11, 0, 9, 6, 7, 4, 10, 2], Costo: 449958
Número de hormigas: 10, alpha: 100, beta: 2, Mejor camino: [14, 0, 13, 6, 4, 12, 1, 5, 7, 8, 11, 2, 9, 10, 3], Costo: 435868
Número de hormigas: 10, alpha: 100, beta: 10, Mejor camino: [40, 0, 13, 6, 4, 12, 1, 5, 7, 8, 11, 2, 9, 10, 3], Costo: 43936
Número de hormigas: 10, alpha: 200, beta: 10, Mejor camino: [5, 12, 2, 0, 6, 11, 1, 3, 13, 4, 14, 9, 8], Costo: 437720
Número de hormigas: 10, alpha: 200, beta: 10, Mejor camino: [5, 12, 2, 0, 6, 11, 1, 3, 13, 4, 7, 14, 8, 10, 9], Costo: 439522
Número de hormigas: 25, alpha: 50, beta: 10, Mejor camino: [13, 12, 8, 5, 14, 1, 11, 6, 7, 4, 13, 9, 0, 10, 2, 3], Costo: 44958
Número de hormigas: 25, alpha: 100, beta: 2, Mejor camino: [11, 1, 3, 4, 5, 8, 12, 2, 10, 7, 6, 13, 9, 0, 14], Costo: 44958
Número de hormigas: 25, alpha: 100, beta: 2, Mejor camino: [11, 1, 3, 4, 5, 8, 12, 2, 10, 7, 6, 13, 9, 0, 14], Costo: 432860
Número de hormigas: 25, alpha: 100, beta: 2, Mejor camino: [11, 1, 3, 4, 5, 8, 12, 2, 10, 7, 6, 13, 9, 0, 14], Costo: 432860
Número de hormigas: 25, alpha: 200, beta: 10, Mejor camino: [12, 3, 6, 14, 12, 6, 1, 13, 8, 7, 10, 3, 4, 2, 9], Costo: 429770
Número de hormigas: 25, alpha: 200, beta: 10, Mejor camino: [2, 3, 6, 14, 1, 3, 7, 0, 9, 14, 1, 2, 10], Costo: 429624
Número de hormigas: 50, alpha: 50, beta: 2, Mejor camino: [2, 3, 6, 14, 1, 3, 7, 0, 9, 14, 1, 2, 10], Costo: 429624
Número de hormigas: 50, alpha: 50, beta: 2, Mejor camino: [2, 3, 6, 7, 4, 13, 9, 0, 11, 6, 7, 4, 10, 13], Costo: 43888
Número de hormigas: 50, alpha: 50, beta: 2, Mejor camino: [3, 14, 8, 5, 4, 1, 3, 7, 0, 9, 14, 1, 10], Costo: 43988
Número de hormigas: 50, alpha: 50, beta: 2, Mejor camino: [6, 4, 8, 0, 10, 11, 3, 7, 14, 2, 5, 12, 13, 1, 9], Costo: 439988
Número de hormigas: 50, alpha: 100, beta: 2, Mejor camino: [6, 4, 8, 0, 10, 11, 3
```

Figura 3: Pruebas de regresión



Figura 4: Pruebas de regresión

3. Lectura

Problema de Optimización Combinatoria Resuelto por ACO

El Algoritmo de Optimización por Colonia de Hormigas (ACO) resuelve problemas de optimización combinatoria convirtiéndolos en problemas de encontrar el camino más corto en un grafo ponderado. Formalmente, esto se describe como:

- Grafo Ponderado G = (V, E): donde V es el conjunto de vértices y E es el conjunto de aristas.
- Función de Costo $c: E \to R^+$: Asigna un costo positivo a cada arista.
- Soluciones S: Conjuntos de caminos en el grafo.
- Función Objetivo $f: S \to R$: Evaluación del costo de cada solución.

Las hormigas artificiales construyen soluciones explorando el grafo, guiadas por niveles de feromonas que reflejan la calidad de soluciones previas.

Cuadro Comparativo de Versiones de ACO

Versión ACO	Descripción
Ant System (AS)	Primera versión básica de ACO. Las hormigas depositan feromo-
	nas proporcionalmente a la calidad de la solución encontrada.
Ant Colony System (ACS)	Introduce la actualización local de feromonas y un mecanismo de
	exploración más agresivo para evitar la convergencia prematura.
Max-Min Ant System (MMAS)	Establece límites máximo y mínimo a los niveles de feromonas,
	ayudando a prevenir la convergencia en soluciones subóptimas.
Rank-Based Ant System (RAS)	Asigna diferentes cantidades de feromonas según el ranking de las
	soluciones, favoreciendo las mejores soluciones encontradas.
Elitist Ant System (EAS)	Similar a AS, pero con un sesgo adicional hacia las mejores solu-
	ciones almacenadas en una memoria global.
Hybrid Ant System (HAS)	Combina ACO con otros métodos de optimización como el reco-
	cido simulado o algoritmos genéticos para mejorar la exploración
	y explotación del espacio de soluciones.

Cuadro 1: Comparación de versiones de ACO

El último congreso registrado es el .^ANTS 2022 - International Conference on Swarm Intelligence". Los tópicos abordados incluyeron:

- Algoritmos bioinspirados
- Optimización multiobjetivo
- Aplicaciones industriales de ACO
- Modelado y análisis teórico de ACO

Las pláticas cubrieron avances recientes en teoría de feromonas, aplicaciones prácticas y nuevas variantes híbridas del algoritmo.

Aplicaciones Relevantes

Tipo de Aplicación	Descripción
Mono-objetivo	Resolución del problema del viajero, optimización de rutas en re-
	des de telecomunicaciones, y diseño de circuitos electrónicos.
Multiobjetivo	Optimización de problemas de programación de la producción,
	planificación de horarios en universidades, y diseño de redes ro-
	bustas.

Cuadro 2: Aplicaciones Relevantes de ACO

4. Conclusiones

Escamilla Resendiz Aldo: El algoritmo de optimización por colonia de hormigas es una técnica metaheurística que ha demostrado ser efectiva en la resolución de problemas de optimización combinatoria. A través de la simulación del comportamiento de las hormigas en la naturaleza, el ACO es capaz de encontrar soluciones de alta calidad en un tiempo razonable. Las diferentes versiones de ACO ofrecen una variedad de enfoques para abordar problemas específicos, y su flexibilidad permite adaptarse a una amplia gama de aplicaciones. En el contexto de la configuración de parámetros, ANOVA ayuda a identificar cuáles parámetros tienen un efecto significativo en el rendimiento del sistema o proceso bajo estudio. Esto se realiza dividiendo la variabilidad total de los datos en componentes atribuibles a diferentes fuentes de variación.

Yañez Martinez Marthon Leobardo: El ACO es una técnica de optimización poderosa que ha demostrado ser efectiva en una variedad de aplicaciones. Al simular el comportamiento de las hormigas en la naturaleza, el ACO es capaz de encontrar soluciones de alta calidad para problemas de optimización combinatoria. Las diferentes versiones de ACO ofrecen una variedad de enfoques para abordar problemas específicos, y su flexibilidad permite adaptarse a una amplia gama de aplicaciones.

Castillo Reyes Diego: El algoritmo de optimización por colonia de hormigas es una técnica metaheurística que ha demostrado ser efectiva en la resolución de problemas de optimización combinatoria. A través de la simulación del comportamiento de las hormigas en la naturaleza, el ACO es capaz de encontrar soluciones de alta calidad en un tiempo razonable. Las diferentes versiones de ACO ofrecen una variedad de enfoques para abordar problemas específicos, y su flexibilidad permite adaptarse a una amplia gama de aplicaciones.