

Problema de la Coloración Mínima

Diego Castillo Reyes^a, Marthon Leobardo Yañez Martínez^a, Aldo Escamilla Resendiz^a y Muñoz González Eduardo^a

^aInvestigadores en formación, ESCOM, IPN

Dra. Miriam Pescador Rojas

Resumen—En este trabajo se presenta el problema de la coloración mínima, el cual es un problema NP-completo. Se propone una solución basada en algoritmos genéticos para encontrar la coloración mínima de un grafo.

Keywords—Coloración Mínima, Genéticos, Algoritmos, Grafos

1. Introducción

El problema de la coloración mínima es un problema NP-completo, el cual consiste en asignar un color a cada vértice de un grafo de tal manera que dos vértices adyacentes no tengan el mismo color. El objetivo es encontrar la coloración mínima, es decir, la menor cantidad de colores posibles para colorear el grafo. Este problema es de gran importancia en la teoría de grafos, ya que tiene aplicaciones en la asignación de horarios, asignación de frecuencias, asignación de canales, entre otros. En este trabajo se propone una solución basada en PSO, un algoritmo de optimización basado en la inteligencia de enjambre, para encontrar la coloración mínima de un grafo.

2. Antecedentes

En una pequeña ciudad de Rusia, Königsberg (Actualmente Kaliningrado, Rusia), existen siete puentes que conectan cuatro islas. Un matemático llamado Leonhard Euler (1707-1783) se preguntó si era posible recorrer todos los puentes una sola vez y regresar al punto de partida. Euler demostró en 1736 que no era posible en su publicación *Solutio problematis ad geometriam situs pertinentis* [1], y para ello utilizó un grafo para representar las islas y los puentes como se ve en la Figura 1.




Figura 1. Grafo de Königsberg

Él demostró utilizando cada puente como una arista y cada isla como un vértice, que no era posible recorrer todos los puentes una sola vez y regresar al punto de partida. Siendo este el primer problema de teoría de grafos, el cual es un área de las matemáticas que estudia las relaciones entre los vértices y las aristas de un grafo. Un grafo es un conjunto de vértices y aristas, donde las aristas son pares no ordenados de vértices. Posteriormente, en 1852, Francis Guthrie planteó el problema de los cuatro colores, el cual consiste en colorear un mapa de tal manera que dos regiones adyacentes no tengan el mismo color. Este problema fue resuelto en 1976 por Kenneth Appel y Wolfgang Haken utilizando una computadora, demostrando que cuatro colores son suficientes para colorear cualquier mapa [2]. A partir de este problema, se han planteado diversos problemas de coloración, entre ellos el problema de la coloración mínima, el cual es un problema NP-completo.

3. Metodología

Para poder resolver el problema de la coloración mínima, se propone una solución basada en algoritmos genéticos. El algoritmo genético elegido fue el de PSO (Particle Swarm Optimization), el cual es un algoritmo de optimización basado en la inteligencia de enjambre. El algoritmo PSO se basa en el comportamiento social de las partículas, las cuales se mueven en un espacio de búsqueda en busca de la mejor solución. Las partículas tienen mejoras cognitivas y mejoras sociales, las cuales les permiten moverse en el espacio de búsqueda. En el caso del problema de la coloración mínima, las partículas representan una coloración de un grafo, y el objetivo es encontrar la coloración mínima. La representación de las partículas es un vector de enteros que representa los colores de los vértices del grafo. El algoritmo PSO se encarga de mover las partículas en el espacio de búsqueda, de tal manera que se encuentre la coloración mínima del grafo. Para evaluar la calidad de una coloración, se utiliza la función objetivo, la cual es el número de colores utilizados en la coloración.

4. Propuesta de solución

```

1  import numpy as np
2  import networkx as nx
3  import random
4  import matplotlib.pyplot as plt
5  import itertools
6
7  # Funcion de fitness
8  def fitness(solution, graph):
9      conflicts = 0
10     for edge in graph.edges:
11         if solution[edge[0]] == solution[edge
12         [1]]:
13             conflicts += 1
14     num_colors = len(set(solution))
15     return num_colors + conflicts * 1000
16
17 def ANOVA(num_particles, w, c1, c2,
18 num_combinations=5):
19     combinaciones = list(itertools.product(
20     num_particles, w, c1, c2))
21     random.shuffle(combinaciones) # Mezcla las
22     combinaciones
23     return combinaciones[:num_combinations] #
24     Devuelve las primeras 'num_combinations'
25     combinaciones
26
27 # PSO parameters
28 num_particles = [30, 50, 100]
29 num_nodos = 10 # Numero de nodos
30 max_iter = 100
31
32 # Parametros de PSO
33 w = [0.3, 0.5, 0.8] # Inercia
34 c1 = [1.0, 1.5, 2.0] # Constante cognitiva
35 c2 = [1.0, 1.5, 2.0] # Constante social
36
37 # Probabilidad de conexion
38 p = 0.5
39
40 # Crear el grafo
41 graph = nx.erdos_renyi_graph(num_nodos, p)
42
43 # Asegurarse de que el grafo no sea totalmente
44 conexo
45 while nx.is_connected(graph):
46     graph = nx.erdos_renyi_graph(num_nodos, p)

```

5. Resultados




Figura 2. Grafo de 10 nodos

En la Figura 2 se muestra un grafo de 10 nodos que no es totalmente conexo, el cual se utilizó para evaluar el algoritmo PSO propuesto.




Figura 3. Coloración del grafo de 10 nodos

En la Figura 3 se muestra el resultado de la coloración del grafo de 10 nodos utilizando el algoritmo PSO propuesto. Como se puede observar, se utilizan 4 colores para colorear el grafo. En la salida de la terminal obtuvimos lo siguiente:

```

1 Iteracion 1/100, Mejor Fitness: 6
2 Iteracion 2/100, Mejor Fitness: 5
3 Iteracion 3/100, Mejor Fitness: 5
4 Iteracion 4/100, Mejor Fitness: 5
5 Iteracion 5/100, Mejor Fitness: 5
6 Iteracion 6/100, Mejor Fitness: 5
7 Iteracion 7/100, Mejor Fitness: 4
8 Iteracion 8/100, Mejor Fitness: 4
9 Iteracion 9/100, Mejor Fitness: 4
10 Iteracion 10/100, Mejor Fitness: 4
11 Iteracion 11/100, Mejor Fitness: 4
12 Iteracion 12/100, Mejor Fitness: 4
13 Iteracion 13/100, Mejor Fitness: 4
14 Iteracion 14/100, Mejor Fitness: 4
15 Iteracion 15/100, Mejor Fitness: 4
16 Iteracion 16/100, Mejor Fitness: 4
17 Iteracion 17/100, Mejor Fitness: 4
18 Iteracion 18/100, Mejor Fitness: 4
19 Iteracion 19/100, Mejor Fitness: 4
20 Iteracion 20/100, Mejor Fitness: 4
21 Iteracion 21/100, Mejor Fitness: 4
22 Iteracion 22/100, Mejor Fitness: 4
23 Iteracion 23/100, Mejor Fitness: 4
24 Iteracion 24/100, Mejor Fitness: 4
25 Iteracion 25/100, Mejor Fitness: 4
26 Iteracion 26/100, Mejor Fitness: 4
27 Iteracion 27/100, Mejor Fitness: 4
28 Iteracion 28/100, Mejor Fitness: 4
29 Iteracion 29/100, Mejor Fitness: 4
30 Iteracion 30/100, Mejor Fitness: 4
31 Iteracion 31/100, Mejor Fitness: 4
32 Iteracion 32/100, Mejor Fitness: 4
33 Iteracion 33/100, Mejor Fitness: 4
34 Iteracion 34/100, Mejor Fitness: 4
35 Iteracion 35/100, Mejor Fitness: 4
36 Iteracion 36/100, Mejor Fitness: 4
37 Iteracion 37/100, Mejor Fitness: 4
38 Iteracion 38/100, Mejor Fitness: 4
39 Iteracion 39/100, Mejor Fitness: 4

```

```

40 # Dibujar el grafo
41 plt.figure(figsize=(8, 6))
42 nx.draw(graph, with_labels=True, node_color='
43 skyblue', node_size=500, edge_color='gray')
44 plt.show()
45
46 # Generar las combinaciones de parametros
47 parametros = ANOVA(num_particles, w, c1, c2,
48 num_combinations=5)
49
50 for i, (num_particles, w, c1, c2) in enumerate(
51 parametros):
52     print(f"Experimento {i + 1}: num_particles={
53 num_particles}, w={w}, c1={c1}, c2={c2}")
54
55     # Inicializacion de particulas
56     particles = [np.random.randint(0, num_nodos,
57 num_nodos) for _ in range(num_particles)]
58     velocities = [np.random.randint(-1, 2,
59 num_nodos) for _ in range(num_particles)]
60     pbest_positions = particles.copy()
61     pbest_scores = [fitness(p, graph) for p in
62 particles]
63     gbest_position = pbest_positions[np.argmin(
64 pbest_scores)]
65     gbest_score = min(pbest_scores)
66
67     # PSO main loop
68     for iteration in range(max_iter):
69         for j in range(num_particles):
70             velocities[j] = (w * velocities[j]
71 + c1 * random.random
72 () * (pbest_positions[j] - particles[j])
73 + c2 * random.random
74 () * (gbest_position - particles[j]))
75
76         # Actualiza la posicion de las
77 particulas
78         particles[j] = np.clip(particles[j]
79 + velocities[j], 0, num_nodos - 1).astype(
80 int)
81
82         # Evaluar nueva posicion
83         current_fitness = fitness(particles[
84 j], graph)
85
86         # Actualizar pbest
87         if current_fitness < pbest_scores[j
88 ]:
89             pbest_positions[j] = particles[j
90 ]
91             pbest_scores[j] =
92 current_fitness
93
94         # Actualizar gbest
95         if current_fitness < gbest_score:
96             gbest_position = particles[j]
97             gbest_score = current_fitness
98
99         print(f"Iteracion {iteration + 1}/{
100 max_iter}, Mejor Fitness: {gbest_score}")
101
102     # Resultado final
103     print("Mejor solucion encontrada:",
104 gbest_position)
105     print("Numero de colores utilizados:", len(
106 set(gbest_position)))
107     print("\n\n")
108
109     # Dibujar el grafo final coloreado para cada
110 experimento
111     color_map = [f"C{color}" for color in
112 gbest_position] # Asigna un color a cada
113 nodo segun la solucipn optima
114     plt.figure(figsize=(8, 6))
115     nx.draw(graph, with_labels=True, node_color=
116 color_map, node_size=500, edge_color='gray')
117     plt.show()

```

Código 1. Algoritmo PSO para el problema de la coloración mínima

```

40 Iteracion 40/100, Mejor Fitness: 4
41 Iteracion 41/100, Mejor Fitness: 4
42 Iteracion 42/100, Mejor Fitness: 4
43 Iteracion 43/100, Mejor Fitness: 4
44 Iteracion 44/100, Mejor Fitness: 4
45 Iteracion 45/100, Mejor Fitness: 4
46 Iteracion 46/100, Mejor Fitness: 4
47 Iteracion 47/100, Mejor Fitness: 4
48 Iteracion 48/100, Mejor Fitness: 4
49 Iteracion 49/100, Mejor Fitness: 4
50 Iteracion 50/100, Mejor Fitness: 4
51 Iteracion 51/100, Mejor Fitness: 4
52 Iteracion 52/100, Mejor Fitness: 4
53 Iteracion 53/100, Mejor Fitness: 4
54 Iteracion 54/100, Mejor Fitness: 4
55 Iteracion 55/100, Mejor Fitness: 4
56 Iteracion 56/100, Mejor Fitness: 4
57 Iteracion 57/100, Mejor Fitness: 4
58 Iteracion 58/100, Mejor Fitness: 4
59 Iteracion 59/100, Mejor Fitness: 4
60 Iteracion 60/100, Mejor Fitness: 4
61 Iteracion 61/100, Mejor Fitness: 4
62 Iteracion 62/100, Mejor Fitness: 4
63 Iteracion 63/100, Mejor Fitness: 4
64 Iteracion 64/100, Mejor Fitness: 4
65 Iteracion 65/100, Mejor Fitness: 4
66 Iteracion 66/100, Mejor Fitness: 4
67 Iteracion 67/100, Mejor Fitness: 4
68 Iteracion 68/100, Mejor Fitness: 4
69 Iteracion 69/100, Mejor Fitness: 4
70 Iteracion 70/100, Mejor Fitness: 4
71 Iteracion 71/100, Mejor Fitness: 4
72 Iteracion 72/100, Mejor Fitness: 4
73 Iteracion 73/100, Mejor Fitness: 4
74 Iteracion 74/100, Mejor Fitness: 4
75 Iteracion 75/100, Mejor Fitness: 4
76 Iteracion 76/100, Mejor Fitness: 4
77 Iteracion 77/100, Mejor Fitness: 4
78 Iteracion 78/100, Mejor Fitness: 4
79 Iteracion 79/100, Mejor Fitness: 4
80 Iteracion 80/100, Mejor Fitness: 4
81 Iteracion 81/100, Mejor Fitness: 4
82 Iteracion 82/100, Mejor Fitness: 4
83 Iteracion 83/100, Mejor Fitness: 4
84 Iteracion 84/100, Mejor Fitness: 4
85 Iteracion 85/100, Mejor Fitness: 4
86 Iteracion 86/100, Mejor Fitness: 4
87 Iteracion 87/100, Mejor Fitness: 4
88 Iteracion 88/100, Mejor Fitness: 4
89 Iteracion 89/100, Mejor Fitness: 4
90 Iteracion 90/100, Mejor Fitness: 4
91 Iteracion 91/100, Mejor Fitness: 4
92 Iteracion 92/100, Mejor Fitness: 4
93 Iteracion 93/100, Mejor Fitness: 4
94 Iteracion 94/100, Mejor Fitness: 4
95 Iteracion 95/100, Mejor Fitness: 4
96 Iteracion 96/100, Mejor Fitness: 4
97 Iteracion 97/100, Mejor Fitness: 4
98 Iteracion 98/100, Mejor Fitness: 4
99 Iteracion 99/100, Mejor Fitness: 4
100 Iteracion 100/100, Mejor Fitness: 4
101 Mejor solucion encontrada: [3 0 7 0 8 7 0 0 3 8]
102 Numero de colores utilizados: 4

```

Código 2. Salida del algoritmo PSO

En esta salida podemos apreciar la rapidez con la que converge el algoritmo de PSO para encontrar la coloración mínima del grafo de 10 nodos.

6. Conclusiones

En conclusión, la coloración mínima de grafos es un problema fundamental en la teoría de grafos y gracias a sus amplias aplicaciones como la asignación de horarios, asignación de frecuencias, asignación de canales, entre otros. Mediante la solución usando PSO hemos logrado solucionar el problema pasando de un tiempo NP a un tiempo polinomial.

Referencias

- [1] L. Euler, «Solutio problematis ad geometriam situs pertinentis,» *Commentarii Academiae Scientiarum Imperialis Petropolitanae*, vol. 8, págs. 128-140, 1736.
- [2] K. Appel y W. Haken, *Every Planar Map Is Four Colorable* (Contemporary Mathematics). Providence, RI: American Mathematical Society, 1976, vol. 98.